

Relatório de Análise NLP (Recuperação da Informação)

Repositório GitHub: <https://github.com/PauloRSL-arch/Analise-NLP>

1. Descrição do Texto Utilizado

O corpus utilizado na análise consiste em um conjunto de 35 documentos 100% originais abordando o tema de Tecnologia e Inovação. Os textos englobam subtemas como Inteligência Artificial, computação quântica, exploração espacial e a atuação de gigantes do Vale do Silício (como Apple, Google e OpenAI). Os documentos variam entre 1 a 2 sentenças e possuem tamanho compatível com o limite de 512 tokens. Os textos foram estruturados em formato .csv contendo as colunas id e documento.

2. Exemplo de POS Tagging

Abaixo, a extração das tags (Part-of-Speech) de uma das sentenças do corpus:

Sentença Original: "A empresa OpenAI foi fundada com o objetivo de desenvolver inteligência artificial."

POS Tagging:

A (DET) empresa (NOUN) OpenAI (PROPN) foi (AUX) fundada (VERB)
com (ADP) o (DET) objetivo (NOUN) de (SCONJ) desenvolver (VERB)
inteligência (NOUN) artificial (ADJ)

3. Exemplo de NER (Reconhecimento de Entidades Nomeadas)

Extração das entidades nomeadas de uma sentença selecionada do texto:

Sentença Original: "Steve Jobs foi um dos principais fundadores da Apple e revolucionou a indústria com o lançamento do iPhone."

Entidades Identificadas:

Steve Jobs (PER - Pessoa) Apple (ORG - Organização)
iPhone (MISC - Produto/Diversos)

4. Gráficos e Tabelas da Análise de Dados

Abaixo estão os resultados sumarizados gerados após a execução da limpeza, POS e análise estatística sobre os documentos do corpus.

Tabela de Frequência de Tokens (Top 10)

Palavra	Frequência	POS Dominante
inteligência	9	NOUN
artificial	8	ADJ
dados	7	NOUN
empresas	6	NOUN
mundo	6	NOUN
desenvolvimento	5	NOUN
tecnologia	5	NOUN
sistema	4	NOUN
grande	4	ADJ
redes	3	NOUN

Distribuição de Entidades (NER)

--	--	--

Tipo de Entidade	Quantidade Total Encontrada	Exemplos Frequentes
ORG (Organizações)	31	OpenAI, Apple, Google, NASA, SpaceX
PER (Pessoas)	12	Steve Jobs, Elon Musk
LOC (Localidades)	8	Vale do Silício, Califórnia
MISC (Diversos)	15	iPhone, Windows, Linux, Bitcoin, TikTok, Zoom

Gráficos Gerados pela Análise de Dados


Estatísticas palavras e tokens por janela

	id	qtdpalavras	qtdtokensbert	qtdpalavrasjanela3	qtdpalavrasjanela5	qtdtokensbertjanela3	qtdtokensbertjanela5
count	35.00	35.00	35.00	35.00	35.00	35.00	35.00
mean	18.00	17.03	19.86	17.03	17.03	19.86	19.86
std	10.25	1.82	3.30	1.82	1.82	3.30	3.30
min	1.00	13.00	14.00	13.00	13.00	14.00	14.00
25%	9.50	16.00	18.00	16.00	16.00	18.00	18.00
50%	18.00	17.00	20.00	17.00	17.00	20.00	20.00
75%	26.50	18.00	21.50	18.00	18.00	21.50	21.50
max	35.00	21.00	28.00	21.00	21.00	28.00	28.00


Estatísticas palavras e tokens em janelas por documento

	id	qtdsentencas	qtdpalavras	qtdtokensbert	totalpalavrasjanela3	totalpalavrasjanela5	totaltokensbertjanela3	totaltokensbertjanela5
count	35.00	35.0	35.00	35.00	35.00	35.00	35.00	35.00
mean	18.00	1.0	17.03	19.86	17.03	17.03	19.86	19.86
std	10.25	0.0	1.82	3.30	1.82	1.82	3.30	3.30
min	1.00	1.0	13.00	14.00	13.00	13.00	14.00	14.00
25%	9.50	1.0	16.00	18.00	16.00	16.00	18.00	18.00
50%	18.00	1.0	17.00	20.00	17.00	17.00	20.00	20.00
75%	26.50	1.0	18.00	21.50	18.00	18.00	21.50	21.50
max	35.00	1.0	21.00	28.00	21.00	21.00	28.00	28.00


Qtd de Sentenças de documentos por quantidade de entidades



Qtd de documentos por quantidade de palavras




Qtd de documentos por quantidade de palavras sem stopwords




Qtd de documentos por quantidade de sentencas




Qtd de documentos por quantidade de tokens




Qtd de documentos por quantidade de verbos e aux




Qtd de documentos por quantidade de verbos




Qtd de documentos por quantidde de locucoes verbais




Qtd de sentancas de documentos por quantidade de palavras desconsiderando stopWord




Qtd de sentecas de documentos por quantidade de substantivos




Qtd de sentecas de documentos por quantidade de locucoes verbias




Qtd de sentencas de documentos por quantidade de palavras




Qtd de sentencas de documentos por quantidade de toknes




Qtd de sentencas de documentos por quantidade de verbos




Qtd de sentencas de documentos por quantidades de verbos aux e substantivos




Qtd de sentencas por quantidade de verbos e aux




Quantidade de documentos por quantidade de entidades



Quantidade de documentos por quantidade de verbos aux e substantivos




Quantidade de documentos por quantidade de substantivos



Tamanhos dos documentos tokenizados antes de classificar



Tamanhos dos documentos tokenizados classificados



Nota: Os arquivos completos (.csv) gerados em cada etapa (documentos_sentenciados, pos_tags, entidades) encontram-se preservados na pasta data/ dentro do repositório da prova.